

# Machine Learning

课件 2      13.10.2021

2021-10-13    02    More on probabilities, Bayes nets

## 一．演绎性推理与归纳性推理

### Deductive vs. plausible reasoning

演绎推理例子：「所有人都会死，苏格拉底是人，所以苏格拉底会死。」

**由一个大前提和一个小前提，推导出结论的推理逻辑**

Deductive reasoning: 演绎性推理

if  $A$  is true, then  $B$  is true 大前提  
 $A$  is true      小前提

---

$B$  is true 结论

“modus ponens”      辩证法

归纳推理例子：「张三赞同我的回答李,赞同我的回答,王五赞同我的回答」

「我的回答收到了赞同」

**找到几个事物的共同点，然后通过共同点去概括这几个事物**

Overview:

- ▶ Assume: if  $A$  is true, then  $B$  is true.
  - ▶  $A$  is true, implies that  $B$  is true.       $A$ 是真的，意味着 $B$ 是真的。
  - ▶  $A$  is false, implies that  $B$  becomes less plausible.       $A$ 是假的，意味着 $B$ 变得不太可信。
  - ▶  $B$  is true, implies that  $A$  becomes more plausible.       $B$ 是真的，意味着 $A$ 变得更加可信。
  - ▶  $B$  is false, implies that  $A$  is false.       $B$ 是假的，意味着 $A$ 是假的。
- ▶ Assume: if  $A$  is true, then  $B$  becomes more plausible.
  - ▶  $A$  is true, implies that  $B$  becomes more plausible.
  - ▶  $A$  is false, implies that  $B$  becomes less plausible.
  - ▶  $B$  is true, implies that  $A$  becomes more plausible.
  - ▶  $B$  is false, implies that  $A$  becomes less plausible.

假设：如果 $A$ 是真的，那么 $B$ 就会变得更加可信

$A$ 是真的，意味着 $B$ 变得更加可信。

$A$ 是假的，意味着 $B$ 变得不那么可信。

$B$ 是真的，意味着 $A$ 变得更加可信。

$B$ 是假的，意味着 $A$ 变得不那么可信。

How can we formalize  
plausibility?

© 2021 by the author(s)

## 将可行性量化考虑

我们需要将机器学习视为概率建模问题。在机器学习中，模型表述了从某个系统中能观察到的所有数据，也就是说模型不仅可以描述所有我们收集到的某种数据，同时它还能描述那些没收集到的同类数据。

## 二. 考克斯和科尔莫戈罗夫的方法

### 1. Cox's and Kolmogorov's approaches

Cox's axioms (formalizing common sense) 考克斯公理(常识的形式化)

- plausibility of  $B$  assuming that  $A$  is true is a real number  $p(B|A)$
- plausibility  $p(B|A)$  complies with common sense
- plausibility  $p(B|A)$  is consistent 考克斯定理 (警告: 证明不是完全严格的)

Cox's theorem (WARNING: proof is not completely rigorous)

- ▶ product rule:  $p(A, B|C) = p(A|B, C)p(B|C) = p(B|A, C)p(A|C)$
- ▶ sum rule:  $p(A|C) + p(\neg A|C) = 1$  假设A是真的 B的可信度是一个实数  $p(B|A)$

Notes

- ▶ the product rule implies Bayes' rule

1. 可分性和可比性——命题的合理性是一个实数，取决于我们掌握的与该命题相关的信息。
2. 常识 - 合理性应该随着模型中合理性的评估而显着变化。
3. 一致性——如果一个命题的合理性可以通过多种方式推导出来，那么所有的结果都必须相等

1. 某些真理由  $\Pr(A | B) = 1$ , 以及某些虚假  $\Pr(A | B) = 0$ .
2.  $\Pr(A | B) + \Pr(\text{not } A | B) = 1$ .
3.  $\Pr(AB | C) = \Pr(A | C) \Pr(B | \neg C) = \Pr(B | C) \Pr(A | BC)$ .

作为贝叶斯概率正确性验证的理由(没啥用)

### 2. Kolmogorov's approaches

$$P(B|A) = \frac{P(B \cap A)}{P(A)}$$

第一公理 (非负性) 对于任意的事件  $P(a) \geq 0$

第二公理（归一化）  $P(\Omega) = 1$

第三公理（可加性）

从柯尔莫果洛夫公理可以推导出另外一些对计算概率有用的法则。

$$P(A \cup B) = P(A) + P(B) - P(A \cap B),$$

$$P(\Omega - E) = 1 - P(E),$$

$$P(A \cap B) = P(A) \cdot P(B|A),$$

这一关系给出了贝叶斯定理。以此可以得出A和B是独立的当且仅当

$$P(A \cap B) = P(A) \cdot P(B),$$

Note: ▶ Debate: is Bayes' rule an axiom?

▶ Plausibilities are just probabilities.

归纳性只是概率

从两个 axioms(公理)推导出 Bayes' rule (规则)

### 三． 概率的规则

#### Rules of probability

如果当我们对世界的某种数据建模时，我们需要预测那些没观察到的数据以及它们之间的不确定性，因此我们可以使用数学中概率论描述这种不确定性并完成「模型」的构建。

贝叶斯法则可以描述为「执果索因」，即知道某个事件发生了，求得该事件最可能是在什么情况下发生的。

贝叶斯法则会告诉我们如何更新对未知世界或假设 (hypothesis) 的知识与信念，且更新假设或信念的信息从我们已知的观察或数据 (data) 中获取

$$p(A|B) = \frac{p(B|A)p(A)}{p(B)}$$

$$P(\text{hypothesis}|\text{data}) = \frac{P(\text{hypothesis})P(\text{data}|\text{hypothesis})}{\sum_{\mathbf{h}} P(\mathbf{h})P(\text{data}|\mathbf{h})}$$

在贝叶斯法法则中，总体数据是未知的，也就是说我们需要使用概率分布表征这种不确定性。在观察到数据之前，我们有先验概率  $P(\text{hypothesis})$ ，它表示我们事先认为任意一个假设及其所出现的概率。此外，对于任意一个假设，我们需要评估根据它能观察到数据的概率，即  $P(\text{data}|\text{hypothesis})$ 。

- ▶ the evidence  $p(\text{data})$  can be calculated from known quantities using the sum rule,  $p(\text{data}) = p(\text{data}|H)p(H) + p(\text{data}|\neg H)p(\neg H)$
- ▶ Bayes' rule calculates your posterior belief  $p(H|\text{data})$  about the hypothesis after seeing the data

Bayes' rule tells you how to update your beliefs!

贝叶斯规则计算出你在看到数据后对假设的后验信念  $p(H|\text{data})$ 。

假设的后验信念

贝叶斯规则告诉你如何更新你的信念!

Bayes' rule (4) — monster vs. mouse

在 Bayes 里引入联合概率一起求解

Basic laws of probability:

|   |              |
|---|--------------|
| $p(A, B) = p(A B)p(B) = p(B A)p(A)$             | product rule |
| $p(A, B C) = p(A B, C)p(B C) = p(B A, C)p(A C)$ | product rule |
| $p(A) + p(\neg A) = 1$                          | sum rule     |
| $p(A C) + p(\neg A C) = 1$                      | sum rule     |
| $p(A, B) + p(A, \neg B) = p(A)$                 | sum rule     |

Lemma 2.1

$p(B|A) = 1$  implies 意味着

- ▶  $p(B|A) = 1$  “modus ponens”
- ▶  $p(B|\neg A) \leq p(B)$
- ▶  $p(A|B) \geq p(A)$
- ▶  $p(\neg A|\neg B) = 1$  “modus tollens”, alternative  $p(A|\neg B) = 0$

Lemma 2.2

$p(B|A) \geq p(B)$  implies

- ▶  $p(B|A) \geq p(B)$
- ▶  $p(B|\neg A) \leq p(B)$
- ▶  $p(A|B) \geq p(A)$
- ▶  $p(\neg A|\neg B) \geq p(\neg A)$